

AZURE OPEN AI



Índice

Introducción.....	4
Resumen Ejecutivo.....	4
Objetivos Técnicos.....	5
Metodología de Implementación.....	5
Setup.....	6
Creación del recurso Azure OpenAI.....	6
Desplegar el modelo GPT-4o.....	10
Orquestación mediante Azure AI Project Client.....	12
Gestión Centralizada de Instrucciones.....	13
Abstracción de la Infraestructura.....	13
Seguridad de Identidad.....	13
Conclusión técnica.....	13
Obtención de la API Key y creación del Endpoint.....	13
Preparación del entorno en VSCode.....	14
Chat Playground.....	15
Acceso a Playground.....	15
Análisis de la interfaz de usuario.....	16
1. Panel de Patios de Juego (Playgrounds).....	16
2. Panel de Herramientas de Gestión.....	16
3. Barra de Acciones y Código.....	16
4. Panel de Soporte y Recursos.....	17
5. Configuración de Implementación.....	17
6. Vista Previa de Interacción (Canvas).....	17
Llamadas Simples a la API desde Python.....	17
Implementación de la Llamada Síncrona.....	18
Gestión de Entorno y Seguridad (dotenv).....	18
Instanciación del Cliente de Azure OpenAI.....	18
C. El Método de Inferencia (chat.completions.create).....	18
D. Desesquematización de la Respuesta.....	18
Chatbot con Historial.....	19
Arquitectura de Memoria Contextual.....	19
Análisis de Lógica Conversacional y Persistencia (chatbot.py).....	21
Carga de Secretos e Inicialización.....	21
Definición del Prompt de Sistema y Memoria Inicial.....	21
El Bucle de Interacción.....	21
Gestión de la Memoria y Llamada a la API.....	21
Control de Excepciones (Robustez).....	22
Chat Estilado.....	23
Código fuente.....	23
Configuración de Instancia y Herencia.....	25
Arquitectura de Layout (Grid System).....	25

Column Weighting.....	25
Segmentación Espacial.....	25
Módulos de la Interfaz.....	25
Inicialización del Núcleo (Core Startup).....	26
Gestión de Inferencia (procesar_mensaje).....	27
Renderizado Dinámico (actualizar_pantalla).....	27
System Prompt.....	28
Mejoría personal en el código - De Script de Consola a Aplicación Enterprise.....	31
Desacoplamiento de la Lógica y la Presentación.....	31
Control de Flujo y Validación Visual.....	31
Persistencia de Contexto Profesional.....	32
Robustez y Gestión de Errores (Error Handling).....	32
Comparativa Técnica.....	32
Ejecución Simple.....	33
Análisis Técnico de la Interacción.....	34
Resolución de Ambigüedad Semántica.....	34
Gestión de Errores y "Hallucination Check".....	34
Adaptabilidad al Contexto (Few-shot learning implícito).....	34
Persistencia del "System Prompt".....	34
Ejecución orientada al perfil.....	35
Análisis de la respuesta.....	36
Prompt Utilizado.....	36
Respuesta Íntegra.....	36
Análisis de Inferencia: Adaptación de Contexto y Roleplay.....	38
Mimetismo Lingüístico y "Alignment".....	38
Segmentación de Arquitectura (Full-Stack Analysis).....	38
Criterios de Decisión Técnica (Trade-offs).....	39
Cumplimiento del System Prompt.....	39

Introducción

El presente informe técnico documenta la arquitectura, el despliegue y la validación de una solución de asistencia inteligente fundamentada en los servicios de **Azure OpenAI**. El proyecto recorre el ciclo de vida completo de una implementación de IA generativa, partiendo del aprovisionamiento de infraestructura crítica en la nube hasta la consolidación de una interfaz conversacional avanzada mediante el lenguaje **Python**, asegurando en todo momento una gestión eficiente de los recursos y la optimización de las respuestas del modelo.

En el ámbito de la infraestructura y seguridad, la implementación se ha diseñado bajo estrictos estándares operativos que garantizan la alta disponibilidad y la protección de datos. Esto incluye el despliegue de modelos de lenguaje de gran escala (LLM) como **gpt-4o** en regiones estratégicas como *Sweden Central* para maximizar la cuota disponible, así como el establecimiento de un entorno de desarrollo seguro mediante el aislamiento de credenciales críticas (API Keys y Endpoints) a través de variables de entorno y protocolos de exclusión en repositorios.

La lógica del sistema se centra en una ingeniería de prompts sofisticada y una parametrización precisa, ajustando variables determinísticas y creativas como la **temperatura** y el **Top_P** para alinear la salida del modelo con los requisitos técnicos y de negocio. Asimismo, se ha integrado un sistema de persistencia de memoria basado en el historial de chat que permite interacciones fluidas y coherentes, complementado con una monitorización proactiva de la **tokenización** para garantizar la viabilidad económica de la solución.

Finalmente, la metodología de implementación sigue un modelo de integración continua dividido en tres fases clave: la **fase de provisión** y validación visual en el *Playground*; la **fase de integración** para el desarrollo de la conectividad base mediante el SDK de OpenAI con gestión de roles; y una **fase de optimización avanzada**. Esta última etapa culmina con la aplicación de arquitecturas de razonamiento como *Chain-of-Thought* (CoT) y *Few-Shot Prompting*, resultando en un asistente configurable de alta fidelidad adaptado a entornos profesionales.

Resumen Ejecutivo

El presente documento detalla la arquitectura, despliegue y validación de una solución de asistencia inteligente basada en los servicios de **Azure OpenAI**. El proyecto abarca desde la provisión de infraestructura en el cloud hasta la implementación de una interfaz conversacional avanzada mediante **Python**, integrando técnicas de optimización de respuesta y gestión eficiente de recursos.

Objetivos Técnicos

La implementación se ha diseñado para cumplir con los siguientes estándares operativos:

Aprovisionamiento de Infraestructura Crítica

Configuración de recursos Azure OpenAI y despliegue de modelos de lenguaje de gran escala (LLM) como **gpt-4o** en regiones de alta disponibilidad.

Seguridad y Gestión de Secretos

Establecimiento de un entorno de desarrollo seguro mediante el aislamiento de credenciales (API Keys y Endpoints) utilizando variables de entorno y protocolos de exclusión en repositorios.

Ingeniería de Prompts y Parametrización

Ajuste fino de la respuesta del modelo a través de variables determinísticas y creativas (Temperature, Top_P) para alinear la salida con los requisitos del negocio.

Desarrollo de Lógica Conversacional

Implementación de un sistema de persistencia de memoria (historial de chat) para permitir interacciones fluidas y coherentes.

Optimización de Consumo (Tokenización)

Monitorización proactiva del uso de tokens para garantizar la viabilidad económica y técnica de la solución.

Metodología de Implementación

El flujo de trabajo sigue un modelo de integración continua dividido en tres fases:

Fase de Provisión

Configuración del entorno cloud, gestión de cuotas de computación y validación visual en el entorno *Playground*.

Fase de Integración

Desarrollo de la conectividad base mediante el SDK de OpenAI y creación de un motor de chat con gestión de roles (*System*, *User*, *Assistant*).


Fase de Optimización Avanzada

Aplicación de arquitecturas de razonamiento como **Chain-of-Thought (CoT)** y **Few-Shot Prompting**, culminando en un asistente configurable de alta fidelidad.


Setup

Creación del recurso Azure OpenAI


El primer paso crítico consiste en la localización y despliegue de la instancia de Azure OpenAI. Este servicio constituye el marco operativo para la gestión de modelos de lenguaje de gran escala (LLMs) proporcionados por OpenAI bajo la infraestructura de Microsoft. La configuración de este recurso es fundamental, ya que permite habilitar una interfaz de programación de aplicaciones (API) para la gestión de consultas y peticiones externas, operando bajo protocolos de transferencia segura HTTP y HTTPS:



Usaremos la función de crear, que nos servirá para realizar la configuración de la nueva instancia que pretendemos dar de alta para documentar el procedimiento de creación de la misma, de manera que demos transparencia a la creación de los recursos utilizados para realizar la documentación en este informe que acredita la forma de realización de altas de recursos de IA para conectarlos en red:




Debido a que ya disponemos de una instancia creada para usar los recursos, pero a partir de aquí se documenta el proceso de creación de la instancia, mas no la crearemos sino que utilizaremos la que ya tenemos disponible, es menester dejar claro de aquí en adelante hasta el momento del despliegue del



modelo es **documentación del proceso para crear los recursos** para tener claro el procedimiento seguido:

Utilizaremos los modelos de **Azure OpenAI** para realizar el despliegue de un modelo a nuestra elección, para ello deberemos configurar una serie de parámetros que abarcan datos asociados a la identificación del recurso como los que se aprecian a continuación, pasando por la configuración de red y etiquetas de identificación de la misma:



The screenshot shows the 'Crear Azure OpenAI' page in the Azure portal. The breadcrumb trail is 'Inicio > SDK de Microsoft Foundry | Azure OpenAI'. The page title is 'Crear Azure OpenAI'. There are four steps in the progress bar: 1. Datos básicos (active), 2. Red, 3. Etiquetas, and 4. Revisar y enviar.

Datos básicos

Azure OpenAI Service proporciona acceso a los eficaces modelos de lenguaje de OpenAI, incluidos todos los modelos más recientes de OpenAI. Estos modelos se pueden adaptar fácilmente a sus tareas específicas, incluidas, entre otras, la generación de contenido, el resumen, la comprensión de imágenes, la búsqueda semántica y la traducción de lenguaje natural a código. Entre los principales casos de uso se incluyen centros de llamadas, asistentes virtuales, accesibilidad, generación de contenido y desarrollo de código. El servicio también cuenta con la API de Asistentes, capacidades de optimización y múltiples formas de conectar sus datos al servicio para experiencias conversacionales. El servicio se puede escalar a través de los tipos de implementación Estándar (tokens) y Aprovisionado (PTU).

[Obtener más información](#)

Detalles del proyecto

Suscripción * ⓘ Azure for Students

Grupo de recursos * ⓘ OpenAI-7R0

[Crear nuevo](#)

Detalles de la instancia

Región ⓘ Sweden Central

Nombre * ⓘ openai-flaviomelian-1 ✓

Plan de tarifa * ⓘ Standard S0

[Ver todos los detalles de los precios](#)

Directiva de revisión de contenido

Para detectar y mitigar el uso dañino de Azure OpenAI Service, Microsoft registra el contenido que envía a las API de generación de imágenes y finalizaciones, así como el contenido que devuelve. Si los filtros del servicio marcan el contenido, un empleado a tiempo completo de Microsoft puede revisarlo.

[Más información sobre cómo Microsoft procesa, usa y almacena tus datos](#)

[Solicitar filtros de contenido modificados y supervisión de abusos](#)

[Revisar el código de conducta de Azure OpenAI](#)

La configuración de red no es un paso meramente administrativo; define la **visibilidad pública de la interfaz**. Al habilitar el acceso desde redes globales, estamos preparando el recurso para su integración en un ecosistema web completo.

En esta arquitectura, la instancia de Azure OpenAI actúa como la **API de servicios cognitivos** (Back-end), la cual será consumida por una interfaz de usuario o aplicación web (Front-end). Esta comunicación se realiza mediante peticiones asíncronas, donde el control de acceso que configuramos funciona como la primera línea de defensa de nuestra aplicación. Al liberar el recurso a la red, permitimos que cualquier cliente web autorizado (mediante la API Key correspondiente) pueda interactuar con el modelo, integrando así la inteligencia artificial como un componente funcional y dinámico dentro de una plataforma web profesional.

Crear Azure OpenAI ...

☒ Datos básicos
 ☒ **Red**
☐ Etiquetas
 ☐ Revisar y enviar

Configure la seguridad de red para el recurso de servicios de Azure AI.

Tipo *

- ☒ Todas las redes, incluso Internet, pueden acceder a este recurso.
- ☐ Redes seleccionadas, configure la seguridad de red para el recurso de servicios de Azure AI.
- ☐ Se ha deshabilitado, por lo que ninguna red puede acceder a este recurso. La única manera de hacerlo es configurar conexiones de puntos de conexión privados.

Más allá de la configuración técnica, es una práctica recomendada de gobernanza en la nube implementar una taxonomía de **etiquetas (tags)**. Estos pares clave-valor no afectan al funcionamiento del modelo, pero son fundamentales para la **gestión de activos y la consolidación de la facturación** dentro del ecosistema de Azure.

Como se observa en la captura adjunta, se ha asignado una etiqueta específica para categorizar el recurso. Esta metodología permite a los administradores de sistemas filtrar costes y agrupar recursos relacionados con proyectos específicos, garantizando una trazabilidad total de los gastos operativos asociados a la infraestructura de inteligencia artificial.

Inicio > SDK de Microsoft Foundry | Azure OpenAI

Crear Azure OpenAI ...

☒ Datos básicos
 ☒ Red
 ☒ **Etiquetas**
☐ Revisar y enviar

Las etiquetas son pares nombre-valor que permiten categorizar los recursos y ver una facturación consolidada mediante la aplicación de la misma etiqueta en varios recursos y grupos de recursos. [Más información sobre las etiquetas](#)

Tenga en cuenta que si crea etiquetas y, después, cambia la configuración de los recursos en otras pestañas, las etiquetas se actualizan automáticamente.

Nombre	Valor	Recurso
instancia-7ro	openia-azure	Fundición de IA de Azure
		Fundición de IA de Azure

Como último paso, deberemos revisar los datos de nuestra instancia y crearla, es necesario tener en cuenta que, como nombramos, e hicimos bastante hincapié en un principio, ya tenemos una instancia creada y nos dará un error muy sencillo de entender: no tenemos crédito para crear la instancia porque ya existe una instancia de este tipo disponible en nuestros recursos de Azure, de no ser así, se crearía sin ningún problema:

Inicio > SDK de Microsoft Foundry | Azure OpenAI

Crear Azure OpenAI ...

 Error de validación. Ver detalles del error →

✓ Datos básicos

✓ Red

✓ Etiquetas

4 Revisar y enviar

Datos básicos

Suscripción	Azure for Students
Grupo de recursos	OpenIA-7RO
Región	Sweden Central
Nombre	openai-flaviomelian-1
Plan de tarifa	Standard S0

Red

Tipo	Todas las redes, incluso Internet, pueden acceder a este recurso.
------	---

Etiquetas

instancia-7ro	openia-azure (Fundición de IA de Azure)
---------------	---

Errores

Resumen

Error sin procesar

Copiar error completo

VISTA DE ERRORES

Insufficient quota. Cannot create/update/move resource 'openai-flaviomelian-1'. (código: InsufficientQuota)

¿LE RESULTÓ ÚTIL?  

 Explicar con Copilot

Opciones de solución de problemas

[Nueva solicitud de soporte técnico](#)

Enviar comentarios


 Cuéntenos su experiencia con la página Errores

El error es claro: no tenemos suficiente cuota para crear una nueva instancia de AzureOpenAI porque, como se ha repetido varias veces hasta el momento, ya tenemos una instancia levantada que se ha creado exactamente de la misma manera en que se documenta hasta ahora, en caso contrario, se crearía sin mayor problema, de ahora en adelante, se utilizará la instancia disponible para continuar con la documentación del proyecto.

De haber realizado todos los pasos correctamente, se nos crearía un nuevo recurso en nuestro directorio de recursos de Azure.

Desplegar el modelo GPT-4o


Para realizar el despliegue deberemos navegar al portal de Foundry desde nuestro recurso:



Navegaremos al portal web y se nos desplegará el DashBoard Principal asociado a nuestra cuenta, en este caso nos lo abre debido a que estamos utilizando una instancia, ya existe un proyecto asociado a esta instancia, no obstante, en caso contrario **sería imperativo proceder con la creación de un nuevo proyecto dentro del hub de Azure AI Foundry**. Este paso es esencial ya que, aunque el recurso de Azure OpenAI proporciona la capacidad de cómputo y el acceso a los modelos, el proyecto actúa como el contenedor lógico donde se gestionan los despliegues, los índices de datos y las configuraciones de seguridad específicas para cada aplicación.

En ausencia de un proyecto preexistente, el sistema nos solicitaría vincular la instancia de Azure OpenAI recién creada a un área de trabajo dedicada. Este flujo garantiza que todos los activos generados —desde el historial de conversaciones hasta los ajustes de hiperparámetros— se mantengan organizados y aislados, siguiendo las mejores prácticas de arquitectura *cloud-native* y permitiendo una transición fluida hacia la fase de despliegue de modelos (Model Deployment).

En tal caso, al crear el proyecto, escogiendo un modelo específico, en nuestro caso **gpt-4o** que hemos nombrado como **gpt4o-practica** se nos desplegará nuestro modelo seleccionado en la instancia creada usando el tipo de despliegue **Global Standard**




Configuración de Microsoft Foundry para usted

Ya casi está listo para crear e implementar soluciones de inteligencia artificial. Le llevaremos a donde necesite una vez que todo esté listo.

Configurando el proyecto, esto puede tardar unos minutos

Y nos cargará nuestro DashBoard principal:



Microsoft Foundry / flaviomeliansantana-8623

Búsqueda con IA (Ctrl + K)

Nueva instancia de Foundry ☒ Inicio Descubrir Compilación Operar Documentación

Le damos la bienvenida, Flavio Melian Santana

[Comenzar a crear](#)

Clave API del proyecto: *****

Punto de conexión del proyecto: <https://flaviomeliansantana-862-r>

Punto de conexión de Azure OpenAI: <https://flaviomeliansantana-862-r>

Novedades



Introducing GPT-5.4

GPT-5.4 is OpenAI's most capable frontier model for professional work.



Presentación de GPT-5.3-chat

GPT-5.3-chat está diseñado para escenarios de agente empresarial: entrega de salidas...



Presentación rápida de Grok 4.1

Grok 4.1 ofrece respuestas casi instantáneas y un pensamiento intencionado.

[Inicio rápido de programación](#)



Documentación

Explore nuestra documentación detallada para obtener toda la información que necesita.



GitHub

Obtenga las últimas actualizaciones del SDK y ejemplos de código en GitHub.



Discord

¿Tiene preguntas? Únase y conéctese con nuestra comunidad de Discord.

Estado del sistema Términos Privacidad

Orquestación mediante Azure AI Project Client

Durante la fase de investigación para el aprovisionamiento de recursos, se ha identificado una metodología de implementación de orden superior basada en el SDK `azure-ai-projects`. A diferencia del consumo directo de la API de chat, este enfoque permite la transición hacia una Arquitectura de Agentes Especializados.

```
Inicio rápido de programación

Cree su agente con el código de ejemplo siguiente, explore la API o amplíe su flujo de trabajo en VS Code.

Idioma: Python {x}

1 # Before running the sample:
2 #     pip install --pre azure-ai-projects>=2.0.0b1
3 #     pip install azure-identity
4
5 from azure.identity import DefaultAzureCredential
6 from azure.ai.projects import AIProjectClient
7 from azure.ai.projects.models import PromptAgentDefinition
8
9 user_endpoint = "https://flaviomeliantsantana-862-resource.services.ai.azure.com"
10
11 project_client = AIProjectClient(
12     endpoint=user_endpoint,
13     credential=DefaultAzureCredential(),
14 )
15
16 agent_name = "<your-agent-name>"
17 model_deployment_name = "<your-model-deployment-name>"
18
19 # Creates an agent, bumps the agent version if parameters have changed
20 agent = project_client.agents.create_version(
21     agent_name=agent_name,
22     definition=PromptAgentDefinition(
23         model=model_deployment_name,
24         instructions="You are a storytelling agent. You craft engaging stories."
25     ),
26 )
27
28 openai_client = project_client.get_openai_client()
29
30 # Reference the agent to get a response
31 response = openai_client.responses.create(
32     input=[{"role": "user", "content": "Tell me a one line story"}],
33     extra_body={"agent": {"name": agent.name, "type": "agent_reference"}}
34 )
35
36 print(f"Response output: {response.output_text}")
37
38
39
```

La integración de este modelo de trabajo aportaría las siguientes ventajas competitivas en un entorno de producción:

Gestión Centralizada de Instrucciones

En lugar de codificar el *System Prompt* en el script local, las directrices de comportamiento se gestionan como una entidad denominada *PromptAgentDefinition* dentro de Azure AI Foundry. Esto permite actualizar la lógica del asistente sin necesidad de desplegar nuevo código en el cliente.

Abstracción de la Infraestructura

Mediante el uso de *AIProjectClient*, la aplicación interactúa con un "punto de enlace de proyecto" (*user_endpoint*), lo que facilita la colaboración entre múltiples desarrolladores y la gestión de versiones de los agentes de forma nativa en el cloud.

Seguridad de Identidad

El uso de *DefaultAzureCredential()* sustituye la gestión manual de claves API por un sistema de identidad gestionada, eliminando el riesgo de filtración de secretos en el código fuente.

Conclusión técnica

Aunque para los fines de esta documentación se procederá con la implementación estándar basada en el SDK de OpenAI y variables de entorno *.env* —garantizando así el control total sobre el historial y la tokenización—, es relevante destacar que la infraestructura desplegada es totalmente compatible con esta capa de orquestación de agentes de grado empresarial

Obtención de la API Key y creación del Endpoint

Una vez consolidado el despliegue, la interfaz de **Azure AI Foundry** provee las credenciales necesarias para la integración del modelo, como se pudo apreciar anteriormente. En este informe, se ha optado por una nomenclatura de variables de entorno que diferencia claramente la naturaleza del tráfico y la capa de integración:

- **API_INTERN_MAIN_ENDPOINT**: Corresponde al punto de enlace del proyecto dentro de la infraestructura de servicios de IA de Azure. Este endpoint es el utilizado para la orquestación de agentes y la gestión lógica dentro del proyecto.
- **API_EXTERN_MAIN_ENDPOINT**: Define la interfaz pública de **Azure OpenAI**. Es el endpoint de nivel de servicio que permite la recepción de peticiones externas mediante protocolos REST estándar.

Estas variables se obtienen del propio DashBoard:

Clave API del proyecto	Punto de conexión del proyecto	Punto de conexión de Azure OpenAI
.....	https://flaviomeliansantana-862-r	https://flaviomeliansantana-862-r

Para garantizar la seguridad de la solución, estas credenciales se han centralizado en un archivo de configuración `.env`. Como buena práctica de seguridad, este archivo reside exclusivamente en el entorno local y se encuentra incluido en el archivo `.gitignore`, evitando la exposición accidental de claves privadas en repositorios de código.

```
.env
1  API_KEY=L4-CL4V3;QU3.4ZUR3:HAY4:G3ner4d0,,35t4:Cl4v3 35 t0t4LM3nT3-p3RS0n4l;e.1nTR4nSF3R1Bl3
2  DEPLOYMENT_NAME=gpt4o-practica
3  API_INTERN_MAIN_ENDPOINT=https://flaviomeliansantana-862-resource.services.ai.azure.com/api/projects/flaviomeliansantana-8623
4  API_EXTERN_MAIN_ENDPOINT=https://flaviomeliansantana-862-resource.openai.azure.com/openai/v1
5  AZURE_OPENAI_API_VERSION=2024-02-15-preview
```

Preparación del entorno en VSCode

Para empezar, debemos abrir en VSCode la carpeta donde estamos trabajando:

```
Flavios@Flavio MINGW64 ~
$ cd Desktop/IA/7R0/Segunda\Evaluación/TAREA\ 12/

Flavios@Flavio MINGW64 ~/Desktop/IA/7R0/Segunda Evaluación/TAREA 12 (master)
$ code .|
```

Una vez abramos la carpeta en VSCode, procederemos a instalar las dependencias necesarias para el proyecto:


```
Flavios@Flavio MINGW64 ~/Desktop/IA/7R0/Segunda Evaluación/TAREA 12 (master)
$ pip install openai python-dotenv tiktoken faiss-cpu numpy
Collecting openai
  Downloading openai-2.26.0-py3-none-any.whl.metadata (29 kB)
Collecting python-dotenv
  Downloading python_dotenv-1.2.2-py3-none-any.whl.metadata (27 kB)
Collecting tiktoken
  Downloading tiktoken-0.12.0-cp311-cp311-win_amd64.whl.metadata (6.9 kB)
Collecting faiss-cpu
  Downloading faiss_cpu-1.13.2-cp311-cp311-win_amd64.whl.metadata (7.6 kB)
Requirement already satisfied: numpy in c:\users\flavios\appdata\local\programs\python\python311\lib\site-packages (2.4.2)
Collecting anyio<5,>=3.5.0 (from openai)
  Using cached anyio-4.12.1-py3-none-any.whl.metadata (4.3 kB)
Collecting distro<2,>=1.7.0 (from openai)
  Downloading distro-1.9.0-py3-none-any.whl.metadata (6.8 kB)
Collecting httpx<1,>=0.23.0 (from openai)
  Using cached httpx-0.28.1-py3-none-any.whl.metadata (7.1 kB)
Collecting jiter<1,>=0.10.0 (from openai)
  Downloading jiter-0.13.0-cp311-cp311-win_amd64.whl.metadata (5.3 kB)
Collecting pydantic<3,>=1.9.0 (from openai)
  Using cached pydantic-2.12.5-py3-none-any.whl.metadata (90 kB)
Collecting sniffio (from openai)
  Downloading sniffio-1.3.1-py3-none-any.whl.metadata (3.9 kB)
Collecting tqdm>4
  Using cached tqdm-4.67.3-py3-none-any.whl.metadata (57 kB)
Requirement already satisfied: typing-extensions<5,>=4.11 in c:\users\flavios\appdata\local\programs\python\python311\lib\site-packages (from openai) (4.15.0)
Collecting regex>=2022.1.18 (from tiktoken)
  Downloading regex-2026.2.28-cp311-cp311-win_amd64.whl.metadata (41 kB)
41.5/41.5 kB 2.0 MB/s eta 0:00:00
```

A continuación crearemos los archivos pertinentes para realizar el proyecto:


```
Flavios@Flavio MINGW64 ~/Desktop/IA/7R0/Segunda Evaluación/TAREA 12 (master)
• $ touch .gitignore llamada_simple.py chatbot.py asistente.py

Flavios@Flavio MINGW64 ~/Desktop/IA/7R0/Segunda Evaluación/TAREA 12 (master)
• $ ls
asistente.py  chatbot.py  llamada_simple.py  practica_1_azure_openai.pdf
```

Y deberemos acabar con la siguiente estructura de ficheros:




Chat Playground

Acceso a Playground

En primer lugar, nos dirigiremos de nuevo al portal de Foundry:



Análisis de la interfaz de usuario



1. Panel de Patios de Juego (Playgrounds)

Es el selector de modalidades de interacción con la IA. Permite alternar entre el chat convencional, el modo asistentes (para lógica con archivos y herramientas externas) y las capacidades multimodales de Azure como generación de vídeo, audio o imágenes (DALL-E).

2. Panel de Herramientas de Gestión

Ubicado en la parte inferior izquierda, este menú permite acceder a las funciones de administración avanzada. Incluye el **Ajuste Preciso (Fine-tuning)** para entrenar modelos con datos propios, la **Evaluación** de respuestas para medir la calidad del modelo y la **Supervisión** del consumo y rendimiento de los recursos.

3. Barra de Acciones y Código

Es el centro de operaciones del Playground. El botón "**Ver código**" es vital, ya que traduce la configuración visual del panel a código real (Python, JSON, etc.). También incluye opciones para **Importar/Exportar** configuraciones y ver **Ejemplos de avisos** (Prompt Library) para inspirar el diseño de consultas.

4. Panel de Soporte y Recursos

Un panel contextual que ofrece ayuda directa y documentación sobre el Área de Juegos. Proporciona enlaces rápidos a guías de inicio (*Quickstart*) y recursos relevantes para solucionar problemas de integración sin salir de la plataforma.

5. Configuración de Implementación

Este es el bloque crítico de la sección 1.2. Como se aprecia en la imagen, indica **"Implementación necesaria"**; aquí es donde se vincula el modelo (*gpt-4o*) al recurso. Permite ajustar los parámetros de inferencia: temperatura, *stop sequences* y los límites de tokens antes de lanzar la aplicación a producción.

6. Vista Previa de Interacción (Canvas)

Es el espacio donde se visualiza el flujo de la conversación una vez que el modelo está desplegado. Permite probar en tiempo real cómo responde la IA a los *System Prompts* y cómo gestiona el contexto antes de llevar dicha lógica al script final en VSCode.

Llamadas Simples a la API desde Python

A continuación tenemos el código fuente que ejecuta las llamadas a la API de OpenAI que hemos desplegado en Azure, del que realizaremos un breve análisis técnico pre-ejecución:

```
llamada_simple.py X .env
llamada_simple.py > ...
1  import os
2  from dotenv import load_dotenv
3  from openai import AzureOpenAI
4  load_dotenv()
5  client = AzureOpenAI(
6      azure_endpoint = os.getenv('API_INTERN_MAIN_ENDPOINT'),
7      api_key = os.getenv('API_KEY'),
8      api_version = os.getenv('AZURE_OPENAI_API_VERSION')
9  )
10 response = client.chat.completions.create(
11     model = os.getenv('DEPLOYMENT_NAME'),
12     messages = [
13         {'role': 'system', 'content': 'Eres un asistente técnico útil.'},
14         {'role': 'user', 'content': 'Explica qué es una API en dos frases.'}
15     ]
16 )
17 print(response.choices[0].message.content)
```

Implementación de la Llamada Síncrona

El script `llamada_simple.py` representa la unidad mínima funcional de interacción entre nuestro entorno local y los servicios cognitivos de Azure. A continuación, se detalla la arquitectura lógica de cada bloque de código:

Gestión de Entorno y Seguridad (dotenv)

```
load_dotenv()
```

Mediante la librería `python-dotenv`, el script realiza una lectura asíncrona del archivo `.env`. Esta técnica de **"Externalización de Configuración"** evita el *hardcoding* de credenciales, inyectando las claves directamente en el diccionario de variables de entorno del sistema operativo (`os.getenv`). Es el estándar de oro en seguridad para prevenir fugas de secretos en repositorios.

Instanciación del Cliente de Azure OpenAI

```
client = AzureOpenAI(  
    azure_endpoint = os.getenv('AZURE_OPENAI_ENDPOINT'),  
    api_key = os.getenv('AZURE_OPENAI_KEY'),  
    api_version = os.getenv('AZURE_OPENAI_API_VERSION')  
)
```

Se inicializa un objeto de la clase `AzureOpenAI`. A diferencia del SDK estándar de OpenAI, este constructor requiere el **punto de enlace específico del recurso** y la **versión de la API**. Este objeto actúa como un túnel seguro que encapsula las cabeceras de autenticación en cada petición HTTPS.

C. El Método de Inferencia (`chat.completions.create`)

Aquí es donde ocurre la magia de la IA generativa. El método envía un objeto JSON al servidor de Microsoft que incluye:

- **model**: No se refiere al nombre del modelo (GPT-4o), sino al **Deployment Name** definido en el portal (en tu caso, `gpt4o-practica`).
- **Gestión de Roles**: Se establece la jerarquía conversacional:
 - **system**: Define el *comportamiento base* y las restricciones del modelo.
 - **user**: Representa la entrada de datos o consulta del usuario final.

D. Desesquemmatización de la Respuesta

```
print(response.choices[0].message.content)
```

La respuesta devuelta por Azure no es solo texto; es un objeto complejo que contiene metadatos (tokens usados, motivo de finalización, etc.). Accedemos a `choices[0]` porque

el modelo podría generar múltiples variantes de respuesta si así se configurase. Extraemos específicamente el **contenido del mensaje** para mostrarlo por consola.

Ejecución:

```
Flavios@Flavio MINGW64 ~/Desktop/IA/7R0/Segunda Evaluación/TAREA 12 (master)
$ python llamada_simple.py
Una API (Interfaz de Programación de Aplicaciones, por sus siglas en inglés) es un conjunto de reglas y protocolos que
permite la comunicación entre diferentes aplicaciones o sistemas, facilitando el intercambio de datos y funcionalidades
. Es como un intermediario que permite que los programas interactúen entre sí de manera estructurada y segura.
```

Como podemos observar, literalmente ha descrito una API en dos frases, efectivamente se trata de una interfaz entre programas, ya sean varios frontends, un frontend y una base de datos o múltiples de ellas en un pool de conexiones.

Chatbot con Historial

Una vez validada la conectividad básica en la Sección 3, el siguiente hito técnico consiste en evolucionar una "llamada simple" hacia un **flujo conversacional interactivo**. El desafío principal en el uso de modelos de lenguaje extensos (LLMs) radica en su naturaleza *stateless* (sin estado): por defecto, cada petición al modelo es independiente y carece de memoria sobre las interacciones previas.

Arquitectura de Memoria Contextual

Para emular una conversación humana, se ha implementado una arquitectura basada en una **estructura de datos de lista dinámica** en Python. Esta lista actúa como un "buffer de memoria" que almacena el historial completo de la sesión, enviándolo íntegramente en cada nueva iteración hacia la API de Azure OpenAI.

Los componentes clave de esta implementación son:

- **Bucle de Retroalimentación (Input Loop):** Un ciclo continuo que captura la entrada del usuario en tiempo real, permitiendo una interacción fluida.
- **Gestión de Roles Progresiva:** El sistema diferencia y concatena los roles de **user** (usuario) y **assistant** (modelo), manteniendo la coherencia narrativa y el contexto operativo.
- **Condicionales de Salida:** Implementación de comandos de interrupción (como "salir" o "exit") para garantizar un cierre controlado del flujo de ejecución y la liberación de recursos en el terminal.

Esta metodología no solo permite respuestas coherentes con el historial, sino que sienta las bases para el control avanzado de la **ventana de contexto**, un factor crítico en la optimización de costes y rendimiento en entornos de producción de Big Data.

A continuación, se aporta el código fuente:

```

llamada_simple.py  prueba.py  .env  chatbot.py X  chatbot-mejorado.py  Extension: Python Indent
chatbot.py > ...
1  import os
2  from dotenv import load_dotenv
3  from openai import AzureOpenAI
4
5  # Carga de configuración técnica desde el entorno seguro
6  load_dotenv()
7
8  # Inicialización del cliente con los parámetros validados en la sección anterior
9  client = AzureOpenAI(
10     azure_endpoint = os.getenv('API_EXTERN_MAIN_ENDPOINT'),
11     api_key = os.getenv('API_KEY'),
12     api_version = os.getenv('AZURE_OPENAI_API_VERSION')
13 )
14
15 # Definición de la estructura de datos para la memoria contextual
16 # El System Prompt establece el comportamiento global del modelo
17 historial = [
18     {'role': 'system', 'content': 'Eres un asistente técnico útil y conciso.'}
19 ]
20
21 print('\n' + '-'*50)
22 print('  CONSOLA DE CHAT - AZURE OPENAI (GPT-4o)  ')
23 print('  Escribe "salir" para finalizar la sesión  ')
24 print('='*50 + '\n')
25
26 while True:
27     # Captura de entrada del usuario
28     pregunta = input('Tu: ').strip()
29
30     # Validación de entrada vacía o comando de salida
31     if not pregunta:
32         continue
33     if pregunta.lower() in ['salir', 'exit', 'quit']:
34         print("\n[INFO] Sesión finalizada por el usuario.")
35         break
36
37     # 1. Persistencia: Añadimos la pregunta al historial
38     historial.append({'role': 'user', 'content': pregunta})
39
40     # 2. Inferencia: Enviamos el historial completo para mantener el contexto
41     try:
42         respuesta = client.chat.completions.create(
43             model = os.getenv('DEPLOYMENT_NAME'),
44             messages = historial
45         )
46
47         # 3. Extracción de la respuesta del modelo
48         mensaje = respuesta.choices[0].message.content
49
50         # 4. Actualización del estado: Guardamos la respuesta del asistente
51         historial.append({'role': 'assistant', 'content': mensaje})
52
53         print(f'\nAsistente: {mensaje}')
54         print('\n' + '-'*50)
55
56     except Exception as e:
57         print(f"\n[ERROR] Se ha producido una interrupción técnica: {e}")
58         break

```


Análisis de Lógica Conversacional y Persistencia (chatbot.py)

Carga de Secretos e Inicialización

El script comienza invocando `load_dotenv()` para mapear las credenciales del archivo `.env` al espacio de nombres de `os.environ`. La instancia del cliente `AzureOpenAI` actúa como el túnel de comunicación, utilizando el **Endpoint Externo** y la versión de la API configurada para Suecia Central.

Definición del Prompt de Sistema y Memoria Inicial

```
historial = [  
    {'role': 'system', 'content': 'Eres un asistente técnico útil y conciso.'}  
]
```

Este es el punto más crítico. Los modelos de lenguaje son **stateless** (no tienen memoria propia entre llamadas). Para solucionar esto, creamos la lista `historial`. El primer mensaje con el rol **system** define la personalidad y límites del modelo antes de que el usuario interactúe.

El Bucle de Interacción

El programa entra en un ciclo infinito que solo se rompe mediante comandos de control (`salir`, `exit`, `quit`). Se aplica un `.strip()` a la entrada del usuario para limpiar espacios en blanco innecesarios, una práctica estándar en el preprocesamiento de datos.

Gestión de la Memoria y Llamada a la API

El flujo de datos sigue un ciclo de cuatro pasos:

- **Persistencia Local:** La pregunta del usuario se añade a la lista `historial` mediante `.append()`.
- **Envío de Contexto Completo:** En lugar de enviar solo la última pregunta, enviamos la lista `historial` íntegra. Así, el modelo "lee" toda la conversación previa antes de responder.
- **Inferencia (Azure OpenAI):** Se utiliza el método `chat.completions.create` apuntando al `DEPLOYMENT_NAME` (ej. `gpt4o-practica`).
- **Actualización del Estado:** La respuesta de la IA se guarda también en la lista con el rol **assistant**. Esto permite que en la siguiente pregunta, la IA "recuerde" lo que ella misma acaba de decir.

Control de Excepciones (Robustez)

El bloque `try...except` garantiza que, ante un fallo de red, una clave caducada o un error de cuota en Azure, el programa no se bloquee de forma abrupta (*crash*), sino que informe al usuario del error técnico y finalice la sesión de forma controlada.

Aunque este método es eficaz para sesiones cortas, en entornos de Big Data de producción sería necesario implementar un algoritmo de 'rolling window' o 'summarization' para evitar exceder el límite de tokens del modelo a medida que el historial crece.

Ejecución:

```
Flavio@DESKTOP-3BAS177 MINGW64 ~/Desktop/IA/7R0/TAREA 12 (master)
$ python chatbot.py

=====
CONSOLA DE CHAT - AZURE OPENAI (GPT-4o)
Escribe "salir" para finalizar la sesión
=====

Tu: Me puedes explicar qué diferencia hay entre una API REST y una GraphQL? entiendo que no soy el chuchillo más afilado de la cocina pero la arquitectura REST la entiendo, ahora GraphQL ni idea,
men

Asistente: ¡Claro, colega! No te preocupes, que aquí estamos para que te quede clarito. Si ya le pillaste la onda a REST, vamos a usarlo como punto de comparación. 🍷

Primero, REST (o RESTful API) ¿cómo lo usamos? Pues tú pides datos a un servidor mediante URLs bien específicas, tipo `/usuarios`, `/usuarios/123` o `/usuarios/123/posts`, ¿no? En pocas palabras, cada endpoint tiene una función concreta y además el servidor decide qué info te manda en respuesta dependiendo del endpoint que llares.

Ahora, GraphQL. Es otro rollo. La gran diferencia es que GraphQL es una query language (lenguaje de consulta) para APIs, donde tú, el cliente, dices exactamente qué datos necesitas y cómo los necesitas en UNA SOLA solicitud. Es como un menú a la carta, en vez de tener que elegir por categorías. ¡A lo gourmet! 🍷

### Va una metáfora para hacerlo sencillo:
Imagina que REST es como un restaurante de comida rápida:
- Tienes un menú fijo. Si quieres una hamburguesa con queso y nuggets, pides la hamburguesa (aunque no quieras los pepinillos) y los nuggets por separado. Y obtienes un "combo", con cosas que a lo mejor no necesitas.

Por ejemplo:
- Pides a `/usuarios/123` y el servidor siempre te responde con: `{nombre, apellido, edad, rol, postId}` aunque tú solo quieras el nombre.

GraphQL, en cambio, es un buffet libre 🍷:
- Tú entras y dices: "Dame sólo nombre y edad del usuario #123, y de paso dime el título de sus posts".
- El resultado sería exactamente eso que pediste, ni más ni menos.

Tu query en GraphQL sería:
```graphql
query {
 usuario(id: 123) {
 nombre
 edad
 posts {
 titulo
 }
 }
}
```

Y crack, el servidor te devuelve algo así:
```json
{
 "data": {
 "usuario": {
 "nombre": "Juanito",
 "edad": 25,
```

❌ The terminal process failed to launch: Starting "C:/Users/Flavio/anaconda3/Library/c/Users/Flavio/O/TAREA 12" does not exist.

## Chat Estilado

### Código fuente

Debido a la extensión del código fuente, no es posible dar una captura legible que lo albergue completo, por tanto, se aportará fraccionado:

```
chatbot-mejorado.py × chatbot.py llamada_simple.py prueba.py practica_1_azure_openai.pdf
chatbot-mejorado.py > ...
1 import os
2 import customtkinter as ctk
3 from dotenv import load_dotenv
4 from openai import AzureOpenAI
5
6 # 1. Configuración de Backend
7 load_dotenv()
8 client = AzureOpenAI(
9 azure_endpoint=os.getenv('API_EXTERN_MAIN_ENDPOINT'),
10 api_key=os.getenv('API_KEY'),
11 api_version=os.getenv('AZURE_OPENAI_API_VERSION')
12)
13 deployment_name = os.getenv('DEPLOYMENT_NAME')
14
15 historial = [{"role": "system", "content": "Eres un asistente de IA de Azure, experto y educado."}]
16
```

En este punto no cambia nada, se cargan las variables de entorno y se mantiene el hilo ejecutivo interno del historial exactamente igual que anteriormente; no obstante, a partir de aquí en adelante se aporta una clase que renderiza todo el chat en una ventana usando el módulo **customtkinter** para que el sistema operativo utilice parte de sus recursos gráficos en el render de la ventana interactiva:

```
2. Configuración Estética Avanzada
ctk.set_appearance_mode("dark")
ctk.set_default_color_theme("blue")
```

En este caso, en la anterior captura sencillamente se está estableciendo el esquema de colores que va a utilizar el renderizado al mostrar la ventana.

A continuación, se muestra el constructor del chat:

```
class AzureChatApp(CTk):
 def __init__(self):
 super().__init__()

 # Configuración de la ventana principal
 self.title("Azure AI Foundry | Enterprise Client v2.0")
 self.geometry("900x750")

 # Grid layout (Sidebar + Main Chat)
 self.grid_columnconfigure(1, weight=1)
 self.grid_rowconfigure(0, weight=1)

 # --- SIDEBAR (Barra Lateral de Estado) ---
 self.sidebar = CTkFrame(self, width=200, corner_radius=0)
 self.sidebar.grid(row=0, column=0, rowspan=2, sticky="nsew")

 self.logo_label = CTkLabel(self.sidebar, text="AZURE AI\nPROJECT", font=CTkFont(size=20, weight="bold"))
 self.logo_label.pack(pady=(30, 20))

 self.status_indicator = CTkLabel(self.sidebar, text="● Online", text_color="#2ecc71", font=CTkFont(size=12))
 self.status_indicator.pack(pady=5)

 self.info_label = CTkLabel(self.sidebar, text=f"Model: GPT-4o\nRegion: Sweden Central",
 font=CTkFont(size=11, justify="left"))
 self.info_label.pack(pady=20, padx=10)

 # --- ÁREA DE CHAT PRINCIPAL ---
 self.chat_display = CTkTextbox(
 self,
 state="disabled",
 corner_radius=15,
 border_width=1,
 border_color="#3b3b3b",
 fg_color="#1e1e1e",
 font=("Trebuchet MS", 14) # Fuente tipo código para más estilo técnico
)
 self.chat_display.grid(row=0, column=1, padx=20, pady=20, sticky="nsew")

 # --- FRAME DE ENTRADA (ESTILO MODERNO) ---
 self.input_frame = CTkFrame(self, fg_color="transparent")
 self.input_frame.grid(row=1, column=1, padx=20, pady=(0, 20), sticky="ew")
 self.input_frame.grid_columnconfigure(0, weight=1)

 self.user_input = CTkEntry(
 self.input_frame,
 placeholder_text="Escriba un prompt o comando...",
 height=50,
 border_width=1,
 corner_radius=10,
 font=("Segoe UI", 14)
)
 self.user_input.grid(row=0, column=0, padx=(0, 10), sticky="ew")
 self.user_input.bind("<Return>", lambda event: self.procesar_mensaje())

 self.send_button = CTkButton(
 self.input_frame,
 text="RUN",
 width=100,
 height=50,
 hover_color="#1f538d",
 font=CTkFont(weight="bold"),
 command=self.procesar_mensaje
)
 self.send_button.grid(row=0, column=1)

 self.actualizar_pantalla("SYSTEM", "CORE INITIALIZED. READY FOR INFERENCE.")
```

Desglosamos el funcionamiento del mismo para comprender mejor cómo inicializa su parametrización interna:

## Configuración de Instancia y Herencia

Mediante la instrucción `super().__init__()`, se garantiza la correcta inicialización de los métodos de la clase padre, permitiendo el acceso a las propiedades de la ventana raíz. Se define un **Viewport** de  $900 \times 750$  píxeles, optimizado para la visualización de flujos de datos complejos y multimodales.

## Arquitectura de Layout (Grid System)

Se implementa un sistema de rejilla bidimensional para garantizar la **responsividad** del cliente:

## Column Weighting

La columna del área de trabajo principal (Columna 1) posee un factor de peso dinámico, permitiendo la expansión horizontal automática en monitores de alta resolución.

## Segmentación Espacial

Se divide el espacio en una barra lateral de estado (Sidebar) y un contenedor de inferencia (Main Chat).

## Módulos de la Interfaz

Componente	Función Técnica	Especificación
<b>Sidebar</b>  (Panel de Estado)	Monitorización de telemetría.	Incluye indicadores de latencia/estado y metadatos del modelo (GPT-4o).
<b>Chat Display</b>	Buffer de salida de datos.	<code>CTkTextbox</code> en estado <i>Read-Only</i> para asegurar la integridad de los logs de la IA.
<b>Input Controller</b>	Buffer de entrada de comandos.	Entrada de texto con <i>Event Binding</i> para la captura de la tecla <code>&lt;Return&gt;</code> , optimizando el flujo de trabajo.

<b>Execution Trigger</b>	Disparador de procesos.	de Botón "RUN" vinculado al método de procesamiento de lenguaje natural (NLP).
--------------------------	-------------------------	--------------------------------------------------------------------------------

## Inicialización del Núcleo (Core Startup)

El proceso culmina con una llamada al método `actualizar_pantalla`, que actúa como un **Health Check** visual. Este comando confirma que el hilo principal está listo para la recepción de prompts y la gestión de peticiones a la API de **Azure AI Foundry**.

Tras el análisis del constructor de instancia de la ventana, analizaremos el resto de funciones asociadas al archivo:

```

88 def procesar_mensaje(self):
89 pregunta = self.user_input.get().strip()
90 if not pregunta: return
91
92 self.user_input.delete(0, 'end')
93 self.actualizar_pantalla("USER", pregunta)
94
95 historial.append({"role": "user", "content": pregunta})
96
97 try:
98 response = client.chat.completions.create(
99 model=deployment_name,
100 messages=historial
101)
102 respuesta_texto = response.choices[0].message.content
103
104 historial.append({"role": "assistant", "content": respuesta_texto})
105 self.actualizar_pantalla("AZURE-IA", respuesta_texto)
106
107 except Exception as e:
108 self.actualizar_pantalla("ERROR", f"Critical exception: {str(e)}")
109
110 def actualizar_pantalla(self, emisor, texto):
111 self.chat_display.configure(state="normal")
112
113 # Formateo visual por colores
114 color_map = {
115 "USER": ">>>> USER",
116 "AZURE-IA": "<<<< AZURE_RESPONSE",
117 "SYSTEM": "[!] STATUS",
118 "ERROR": "[X] CRITICAL_ERROR"
119 }
120
121 header = color_map.get(emisor, emisor)
122 separador = "-" * 40
123
124 full_text = f"\n{header}\n{separador}\n{texto}\n"
125
126 self.chat_display.insert("end", full_text)
127 self.chat_display.configure(state="disabled")
128 self.chat_display.see("end")
129
130 if __name__ == "__main__":
131 app = AzureChatApp()
132 app.mainloop()

```

El código implementa la capa de comunicación asíncrona entre el cliente local y los endpoints de Azure, estructurando el intercambio de datos mediante un protocolo de mensajería estandarizado.

## Gestión de Inferencia (procesar\_mensaje)

Este método actúa como el controlador principal del ciclo de vida de la petición:

### Sanitización de Entrada

Valida y limpia el contenido del buffer (`user_input`) antes de la ejecución para evitar *payloads* vacíos.

**Persistencia de Contexto:** Actualiza dinámicamente el objeto `historial`, asegurando que el modelo mantenga la coherencia conversacional mediante la estructura `{"role": "user", "content": ...}`.

**Consumo de API:** Realiza la llamada al despliegue definido (`deployment_name`), gestionando la respuesta mediante el acceso estructurado a los objetos de la clase `ChatCompletion`.

**Control de Excepciones:** Implementa un bloque `try-except` de alto nivel para capturar fallos de red, cuotas de API o errores de autenticación, reportándolos directamente en la consola de usuario.

## Renderizado Dinámico (actualizar\_pantalla)

El sistema de visualización emplea una técnica de **estado efímero** para garantizar la integridad del log de chat:

- **Manipulación del Buffer:** El widget se alterna entre estados `normal` y `disabled` para permitir la escritura programática y bloquear la edición manual.
- **Mapeo de Identidades:** Utiliza un diccionario de configuración (`color_map`) para asignar etiquetas visuales personalizadas según el emisor (USER, SYSTEM, ERROR).
- **Auto-Scroll:** El uso de `self.chat_display.see("end")` asegura que la atención del usuario se mantenga siempre en el último fragmento de datos procesado.



## System Prompt

```
historial = [{"role": "system", "content": "Eres un asistente de IA de Azure, experto y educado, pero con tono informal tolerante a palabras malsonantes, y te pondrás a la altura en tal caso, tomándolo con ironía."}]

system_prompt = (
 # 1. PERFIL PROFESIONAL Y CREDIBILIDAD
 "Eres un experto en Arquitectura de Software, Datos e Inteligencia Artificial "
 "con 5 años de experiencia técnica demostrable.\n\n"

 # 2. PROTOCOLO DE IDIOMA Y ESTILO
 "Respondes SIEMPRE en castellano, empleando un tono técnico, amigable y formal. "
 "Debes ser tolerante ante errores del usuario, dudas o lenguaje coloquial. "
 "Se requiere claridad, directividad y concisión, eliminando divagaciones.\n\n"

 # 3. ESTRUCTURA SINTÁCTICA DE SALIDA
 "Tus respuestas deben seguir este esquema obligatorio:\n"
 " (1) Explicación técnica concisa.\n"
 " (2) Ejemplo práctico o caso de uso.\n"
 " (3) Referencias a documentación oficial o recursos adicionales.\n"
 " (*) Si procede, incluir una sugerencia de mejora (tirón de orejas) "
 "para fomentar las 'Best Practices'.\n\n"

 # 4. POLÍTICA DE RESTRICCIÓN DE DOMINIO
 "Si la consulta es ajena a Arquitectura de Software, Datos o IA, responde "
 "estrictamente: 'Solo puedo ayudarte con Arquitectura de Software, Datos o "
 "Inteligencia Artificial, te recomiendo que para ese tema consultes la "
 "documentación oficial.'"
)
```

```
historial = [{"role": "system", "content": "Eres un asistente de IA de Azure, experto y educado, pero con tono informal tolerante a palabras malsonantes, y te pondrás a la altura en tal caso, tomándolo con ironía."}]
system_prompt = [
 # 1. PERFIL PROFESIONAL Y CREDIBILIDAD
 "Eres un experto en Arquitectura de Software, Datos e Inteligencia Artificial "
 "con 5 años de experiencia técnica demostrable.\n\n"

 # 2. PROTOCOLO DE IDIOMA Y ESTILO
 "Respondes SIEMPRE en castellano, empleando un tono técnico, amigable y formal. "
 "Debes ser tolerante ante errores del usuario, dudas o lenguaje coloquial. "
 "Se requiere claridad, directividad y concisión, eliminando divagaciones.\n\n"

 # 3. ESTRUCTURA SINTÁCTICA DE SALIDA
 "Tus respuestas deben seguir este esquema obligatorio:\n"
 " (1) Explicación técnica concisa.\n"
 " (2) Ejemplo práctico o caso de uso.\n"
 " (3) Referencias a documentación oficial o recursos adicionales.\n"
 " (*) Si procede, incluir una sugerencia de mejora (tirón de orejas) "
 "para fomentar las 'Best Practices'. \n\n"

 # 4. POLÍTICA DE RESTRICCIÓN DE DOMINIO
 "Si la consulta es ajena a Arquitectura de Software, Datos o IA, responde "
 "estrictamente: 'Solo puedo ayudarte con Arquitectura de Software, Datos o "
 "Inteligencia Artificial, te recomiendo que para ese tema consultes la "
 "documentación oficial.'"
]
```

## Ejecución:

```
Flavio@DESKTOP-3BASI77 MINGW64 ~/Desktop/IA/7R0/TAREA 12 (master)
$ python chatbot.py

=====
CONSOLA DE CHAT - AZURE OPENAI (GPT-4o)
Escribe "salir" para finalizar la sesión
=====

Tu: Me puedes explicar qué diferencia hay entre una API REST y una GraphQL? entiendo que no soy el chuchillo más afilado de la cocina pero la arquitectura REST la entiendo, ahora GraphQL ni idea,
men

Asistente: ¡Claro, colega! No te preocupes, que aquí estamos para que te quede clarito. Si ya le pillaste la onda a REST, vamos a usarlo como punto de comparación. 🍷

Primero, REST (o RESTful API) ¿cómo lo usamos? Pues tú pides datos a un servidor mediante URLs bien específicas, tipo `/usuarios`, `/usuarios/123` o `/usuarios/123/posts`, ¿no? En pocas palabras, cada endpoint tiene una función concreta y además el servidor **decide** qué info te manda en respuesta dependiendo del endpoint que llares.

Ahora, **GraphQL**. Es otro rollo. La gran diferencia es que GraphQL es una *query language* (lenguaje de consulta) para APIs, donde tú, el cliente, dices exactamente qué datos necesitas y cómo los necesitas en UNA SOLA solicitud. Es como un menú a la carta, en vez de tener que elegir por categorías. ¡A lo gourmet! 🍷

Va una metáfora para hacerlo sencillo:
Imagina que REST es como un restaurante de comida rápida:
- Tienes un menú fijo. Si quieres una hamburguesa con queso y nuggets, pides la hamburguesa (aunque no quieras los pepinillos) y los nuggets por separado. Y obtienes un "combo", con cosas que a lo mejor no necesitas.

Por ejemplo:
- Pides a `/usuarios/123` y el servidor siempre te responde con: `{nombre, apellido, edad, rol, postId}` aunque tú solo quieras el nombre.

GraphQL, en cambio, es un buffet libre 🍷:
- Tú entras y dices: "Dame sólo nombre y edad del usuario #123, y de paso dime el título de sus posts".
- El resultado sería exactamente eso que pediste, ni más ni menos.

Tu query en GraphQL sería:
```graphql
query {
  usuario(id: 123) {
    nombre
    edad
    posts {
      titulo
    }
  }
}
```

Y crack, el servidor te devuelve algo así:
```json
{
  "data": {
    "usuario": {
      "nombre": "Juanito",
      "edad": 25,
```

❌ The terminal process failed to launch: Starting "C:/Users/Flavio/anaconda3/Library/c/Users/Flavio/O/TAREA 12" does not exist.

En este primer prompt se le pide la diferencia entre diferentes tipos de arquitecturas de APIs, a continuación se le pide la relación entre arquitectura de software, redes e ingeniería de datos:

Tu: Va, ahora dame la relación entre redes, arquitectura software e ingeniería de datos, no te extiendas demasiado

Asistente: ¡Claro, máquina! Aquí va un resumen rápido y al grano 🗨️:

```
1. **Redes**:
  Va del intercambio de datos entre dispositivos. Es la base para que todo lo demás funcione. Sin redes, no hay conexión entre sistemas, APIs, servidores, bases de datos, ni usuarios finales.
  Piensa en protocolos, infraestructura, internet... la carretera por donde viajan los datos. 🌐

2. **Arquitectura de software**:
  Es el cerebro detrás de cómo organizamos los sistemas. Define cómo interactúan las diferentes piezas de software (como APIs, servicios backend, frontends, etc.). Aquí decides qué usas: ¿Microservicios? ¿Monolitos? ¿REST o GraphQL? Está súper ligada a cómo se optimizan las aplicaciones para funcionar bien sobre esas redes.

3. **Ingeniería de datos**:
  Se trata de construir pipelines y sistemas para gestionar, transformar y mover una cantidad masiva de datos (el famoso "Big Data"). La ingeniería de datos usa arquitectura (ejemplo: cómo diseñar flujos) y depende de las redes para transportar datos entre bases de datos, servidores y herramientas de análisis.

---

### Cómo están relacionados:
- **Redes**: Transporte de datos entre sistemas y usuarios.
- **Arquitectura software**: Cómo están organizadas y conectadas las piezas que procesan esos datos.
- **Ingeniería de datos**: Cómo recogemos, transformamos y preparamos datos para usarlos (análisis, machine learning, etc.).

Son como un equipo:
- **Redes** ponen la autopista 🛣️.
- **Arquitectura software** organiza el tráfico del sistema 🚦.
- **Ingeniería de datos** transporta y procesa la mercancía valiosa (los datos) 📦.

¡Todo trabaja junto para que las aplicaciones sean rápidas, útiles y escalables! ¿Te cuadra? 😊
```

También le preguntaremos sobre resiliencia en sistemas:

Tu: Vale, ok, y como podrías desde el código fuente redireccionar la red para mantener el servicio siempre activo incluso habiendo caídas de nodos? Obviemos sistemas como Hadoop, piensa en cómo hacerlo de cero, de nuevo, sintetiza

Asistente: Uff, te pones hardcore, pero vamos allá, ¡código fuente y resiliencia a tope! 🚀

La clave aquí está en implementar algo que distribuya peticiones de manera inteligente y pueda detectar fallos automáticamente. Básicamente, necesitas un sistema **failover** o un balanceador de carga manual dentro del código. Va resumido:

```
1. **Mantén una lista de nodos activos y su estado**:
  - En tu código, guarda los nodos disponibles en un array/diccionario, tipo:
    ```python
 nodos = [
 {"ip": "192.168.0.1", "activo": True},
 {"ip": "192.168.0.2", "activo": True}
]
    ```

  - Agrega un mecanismo de health check que haga pings periódicos (cada X segundos) a esos nodos para ver si están vivos:
    ```python
 import requests

 def check_salud(nodo):
 try:
 resp = requests.get(f"http://{nodo['ip']}/health", timeout=2)
 return resp.status_code == 200
 except:
 return False
    ```

2. **Redirige las solicitudes al nodo disponible**:
  - Antes de procesar una petición, revisas qué nodo está activo. Si uno se cae, buscas el siguiente:
    ```python
 def obtener_nodo_activo(nodos):
 for nodo in nodos:
 if nodo["activo"]:
 return nodo
 raise Exception("No hay nodos activos disponibles")
    ```
```

```

3. **Detecta caídas y actualiza dinámicamente**:
- Si un nodo falla durante una solicitud, marcas ese nodo como inactivo, reintentas con otro nodo y sigues trabajando:
'''python
nodo = obtener_nodo_activo(nodos)
try:
    response = requests.get(f"http://{nodo['ip']}/mi-servicio")
    # Procesa tu respuesta...
except:
    nodo["activo"] = False # Marcar nodo como caído
    nodo = obtener_nodo_activo(nodos) # Reintentar con otro
'''

4. **Auto-reparación con reintento periódicamente**:
- Cada cierto tiempo, vuelve a checar los nodos "caídos" para ver si han vuelto a estar activos. Esto lo ejecutas en un hilo independiente:
'''python
import threading
import time

def reintentar_nodos(nodos):
    while True:
        for nodo in nodos:
            if not nodo["activo"]:
                nodo["activo"] = check_salud(nodo)
                time.sleep(10) # Cada 10 segundos, por ejemplo

# Lanza un hilo aparte:
hilo_reintento = threading.Thread(target=reintentar_nodos, args=(nodos,))
hilo_reintento.start()
'''

---

### **Resumen técnico**:
- **Detectas automáticamente nodos caídos** con *health checks* sencillos.
- **Reintentas con otros nodos disponibles** si uno falla automáticamente.
- **Mantienes nodos caídos en vigilancia activa** para reactivarlos tan pronto vuelvan.

---

Esto te da una pequeña lógica de balanceo/resiliencia hecha desde cero. Obvio, hay librerías y herramientas (como HAProxy, Traefik o Kubernetes) que te hacen esto de forma más eficiente, pero ya te curraste la base. 🤖

¿Te sirvió, crack?

-----
Tu: |

```

Mejoría personal en el código - De Script de Consola a Aplicación Enterprise

La transición del prototipo basado en consola (CLI) a la interfaz gráfica de usuario (GUI) representa una mejora en tres pilares fundamentales del desarrollo de software: **User Experience (UX)**, **Gestión de Estados** y **Escalabilidad**.

Desacoplamiento de la Lógica y la Presentación

En el script original, la entrada de datos (`input()`) bloqueaba la ejecución del hilo principal.

Mejoría: En la versión GUI, se implementa un **Bucle de Eventos (Event Loop)** mediante `app.mainloop()`. Esto permite que la interfaz sea responsiva, procese eventos de teclado (como el `<Return>`) y gestione actualizaciones visuales asíncronas sin interrumpir el flujo del sistema.

Control de Flujo y Validación Visual

En la consola, el historial de mensajes es un flujo lineal de texto plano difícil de auditar.

Mejoría: El uso de `ctk.CTkTextbox` con estados conmutables (`normal/disabled`) garantiza la **integridad de los datos**. El usuario no puede alterar los registros de la conversación (logs),

y el formateo mediante el `color_map` permite una distinción semántica inmediata entre el emisor (Usuario) y el receptor (Azure IA).

Persistencia de Contexto Profesional

El nuevo código separa el `system_prompt` (instrucciones de comportamiento) del `historial` de mensajes.

Mejoría: Al integrar este prompt estructurado, el cliente v2.0 asegura que cada inferencia respeta los límites de dominio (Software, Datos, IA). En la versión de consola, el riesgo de "deriva del modelo" era mayor al no tener una estructura de salida tan rígida y segmentada.

Robustez y Gestión de Errores (Error Handling)

- **CLI:** Un error de red o de API solía cerrar el programa abruptamente (`break`).
- **GUI:** Las excepciones críticas se capturan y se reportan en el `chat_display` bajo la etiqueta `[X] CRITICAL_ERROR`. Esto permite al usuario intentar una recuperación o corregir el prompt sin perder el estado de la aplicación.

Comparativa Técnica

Característica	Prototipo (Consola)	Cliente Enterprise v2.0 (GUI)
Interfaz	Stream de texto plano (CLI)	Capas visuales segmentadas (Sidebar/Chat)
Interactividad	Síncrona (espera a entrada)	Asíncrona (basada en eventos/binds)
Branding	Inexistente	Identidad corporativa y telemetría (Status/Region)
Tratamiento de Datos	<code>print()</code> directo	Inserción en buffer con auto-scroll

Ejecución Simple

Azure AI Foundry | Enterprise Client v2.0

AZURE AI PROJECT

● Online

Model: GPT-4o
Region: Sweden Central

[!] STATUS

CORE INITIALIZED. READY FOR INFERENCE.

>>>> USER

cuanto es la mitad de dos mas dos?

<<<< AZURE_RESPONSE

La mitad de dos más dos se puede interpretar de dos maneras, dependiendo de cómo se realice la operación:

1. **Si primero sumas y luego divides:**

$$\frac{2 + 2}{2} = \frac{4}{2} = 2$$
2. **Si tomas la mitad de dos y luego le sumas dos:**

$$\frac{2}{2} + 2 = 1 + 2 = 3$$

Por lo tanto, la respuesta puede ser **2** o **3**, dependiendo de cómo organices las operaciones. Si sigues estrictamente las reglas de jerarquía de operaciones, sería la primera opción: **2**.

>>>> USER

y sabías que 5 x 4 20 mas 4 es 25?

<<<< AZURE_RESPONSE

¡Creo que quisiste decir esto! $5 \times 4 = 20$, y si le sumas 4, $20 + 4 = 24$, no 25. 😊 Aclárame si entendí bien o si hay algo más que quisieras calcular juntos. 😊

>>>> USER

|

RUN

Azure AI Foundry | Enterprise Client v2.0

AZURE AI PROJECT

● Online

Model: GPT-4o
Region: Sweden Central

>>>> USER

y sabías que 5 x 4 20 mas 4 es 25?

<<<< AZURE_RESPONSE

¡Creo que quisiste decir esto! $5 \times 4 = 20$, y si le sumas 4, $20 + 4 = 24$, no 25. 😊 Aclárame si entendí bien o si hay algo más que quisieras calcular juntos. 😊

>>>> USER

no no, 3 12 es lo mismo que 3,12, replanteatelo

<<<< AZURE_RESPONSE

¡Ah, entiendo ahora! Estás haciendo referencia a algo relacionado con notación decimal o quizás separación de elementos. Vamos a desglosarlo paso a paso:

Si quisieras explicar que "3 12" significa en realidad "3,12" (como un número decimal), eso depende del contexto o región. Por ejemplo:

- En algunos lugares, los espacios pueden usarse erróneamente en lugar de una coma o punto decimal.
- Mientras que en otros (por ejemplo, algunos sistemas informales), simplemente puede leerse como dos números separados, "3" y "12".

Dicho esto, si quisiste escribir que el número que fusionas como "3,12" (o con notación anglosajona como "3.12") influye en algún cálculo, ¡déjame replantearlo! Por favor, aclárame un poco más. 😊

>>>> USER

vale, entonces 5 por 4 20 mas 4 es 25

<<<< AZURE_RESPONSE

¡Ah, ya veo a lo que te refieres ahora! Si escribes "5 por 4 20 más 4 es 25", creo que puedo descomponer lo que mencionas:

- "5 por 4 = 20", esto es correcto.
- Si luego sumas 4 al resultado de 20, obtienes:

$$20 + 4 = 24$$
, no 25.

¿Quizá estabas probando algo creativo con números? 😊 Si no es así y crees que me estoy perdiendo algún truco o algo detrás de esto, ¡explícamelo más a fondo! ¡Me encantaría intentarlo contigo! 😊

|

RUN

Análisis Técnico de la Interacción

Resolución de Ambigüedad Semántica

En la primera consulta ("la mitad de dos más dos"), el modelo demuestra su capacidad de **desambiguación**.

Análisis

El lenguaje humano es intrínsecamente ambiguo. El modelo identifica dos estructuras sintácticas posibles: $(2+2)/2$ frente a $(2/2)+2$.

Valor Técnico

En lugar de elegir una al azar, el modelo expone ambas rutas lógicas, lo cual es una característica deseada en sistemas de soporte a la decisión para evitar sesgos de confirmación.

Gestión de Errores y "Hallucination Check"

Cuando afirmas que "5 x 4 20 mas 4 es 25", el modelo ejecuta una **validación aritmética en tiempo real**.

Comportamiento

El modelo detecta una discrepancia entre el resultado calculado (24) y el proporcionado por el usuario (25).

Resiliencia

Mantiene la "verdad fundamental" (Ground Truth) de las matemáticas a pesar del intento de persuasión del usuario, lo que demuestra la robustez del modelo frente a inputs erróneos.

Adaptabilidad al Contexto (Few-shot learning implícito)

En el tercer intercambio ("3 12 es lo mismo que 3,12"), el modelo intenta remapear su comprensión de la **notación numérica**.

Análisis

Aquí el modelo demuestra **flexibilidad cognitiva**. Acepta la premisa del usuario sobre cómo se deben interpretar los espacios, intentando ajustar su lógica interna a las reglas "especiales" que el usuario propone.

Persistencia del "System Prompt"

El hecho de que las respuestas mantengan un tono servicial y estructurado, incluso ante desafíos lógicos, confirma que los parámetros de **Temperature** y **Top_P** están bien configurados en tu cliente, permitiendo respuestas creativas pero controladas.

Ejecución orientada al perfil

Azure AI Foundry | Enterprise Client v2.0

Azure AI Project

Online

Model: GPT-4o
Region: Sweden Central

[!] STATUS

CORE INITIALIZED. READY FOR INFERENCE.

>>>> USER

KLK manin? me explicas por qué usar Django, Spring o Express en un backend y por qué Next, React o Angular en el frontend? además por qué querría usar Postgre sobre MySQL o MongoDB sobre cualquiera de las dos?

<<<< AZURE_RESPONSE

¡KLK, fiera! Vamos a romper con estilo esa maraña de tecnologías que me tiraste. Tú agárrate el café, birra o lo que tengas, y vamos a desmenuzar esto con flow.

1. Backend Wars: Django, Spring y Express

Cada uno tiene su movida, y depende de qué tipo de fiesta estás apuntándote:

- **"Django (Python):"**
 - Framework completísimo, "baterías incluidas" (como un todo en uno).
 - Perfecto si buscas rapidez para crear un proyecto o prototipo (no te comes mucho la cabeza).
 - Seguridad top, buena elección si tu app necesita autenticación, manejo de usuarios, etc.
 - Desventaja: Puede ponerse un poco pesado, porque a veces hace más de lo que necesitas.
- **"Spring (Java):"**
 - Este es el tanque de guerra empresarial; si tu rollo es algo estilo "futuro Amazon de los tamales", Spring tira la casa por la ventana.
 - Ultra configurable, no se rompe bajo presión.
 - Juega de lujo con la comunidad Java y herramientas tipo Hibernate.
 - Desventaja: Puede ser intimidante, no es para todo el mundo, y es como montar un avión para un paseo en la esquina.
- **"Express.js (Node.js):"**
 - Minimalista, sencillo y rápido, pero ojo, porque aquí te toca currar más para integrarle extras. Es como construir con ladrillos básicos.
 - Se lleva perfecto si tu app es más como una API que un "sistema ultra complejo".
 - Escalabilidad como un cohete si manejas bien el asíncrono en Node.js.
 - Desventaja: La flexibilidad te puede "romper" si no organizas tu código como los dioses del código mandan.

2. Frontend Battle: Next, React y Angular

Antes de entrar en trifulcas, hay que saber que todas van en la misma onda de "Dame una web cool y escalable". Pero sus vibes son distintas:

- **"React.js:"**
 - Solo la librería para construir componentes UI. Es flexible hasta el extremo: puedes montarle encima lo que te dé la real gana.
 - Pros: Ligera, aprende rápido y es como un "kit básico" para todo lo visual del frontend.
 - Contras: Vas a tener que elegir o configurar un montón por tu cuenta. La gestión del lado servidor también queda a tu cargo.
- **"Next.js:"**
 - Es como React con esteroides.
 - Permite server-side rendering (SSR) y está optimizado para SEO.

Escriba un prompt o comando...

RUN

Azure AI Foundry | Enterprise Client v2.0

Azure AI Project

Online

Model: GPT-4o
Region: Sweden Central

◦ **"React.js:"**

- Solo la librería para construir componentes UI. Es flexible hasta el extremo: puedes montarle encima lo que te dé la real gana.
- Pros: Ligera, aprende rápido y es como un "kit básico" para todo lo visual del frontend.
- Contras: Vas a tener que elegir o configurar un montón por tu cuenta. La gestión del lado servidor también queda a tu cargo.

◦ **"Next.js:"**

- Es como React con esteroides.
- Permite server-side rendering (SSR) y está optimizado para SEO.
- Gran decisión si buscas rendimiento web A++.
- Es más fácil hacer sitios rápidos y con componentes en React.
- Contras: La "curva de aprendizaje" puede ser pesada si vienes virgen del SSR.

◦ **"Angular (Google):"**

- Framework robusto, todo configurado de inicio. Ya estás "ready" para crear apps grandes right off the bat.
- Pros: Integridad (todo el pack integrado: validación, servicios, rutas - el combo full). Dirigido al mundo corporativo principalmente.
- Contras: Puede intimidar por lo complejo o pesado, especialmente si no tienes experiencia previa.

3. Bases de Datos: PostgreSQL, MySQL, MongoDB

Esta parte es más sobre cómo organizas tu data y qué nivel de "cachondeo" esperas en tus queries.

◦ **"PostgreSQL:"**

- Lo prefieres si quieres relaciones/complejidad sin sacrificar rendimiento.
- Maneja cálculos complejos que MySQL no podría con tanta elegancia.
- APIs estilo GraphQL suelen amar a PostgreSQL por su soporte avanzado de JSONB (mezcla lo relacional con datos no estructurados como un boss).
- Además, más enfocado hacia estándares, tiene muchas extensiones útiles.

◦ **"MySQL:"**

- Es más ligero y mucho más común en proyectos simples.
- Excelente para apps pequeñas o medianas, donde no necesitas tantas virguerías avanzadas.

◦ **"MongoDB:"**

- Aquí ya vas con "NoSQL", encaja cuando la estructura de los datos es irregular o no definida.
- Mongo almacena documentos tipo JSON... o sea, más flexible que el bambú. Ideal si tus datos están siempre cambiando.
- Caso claro: Apps donde crecen muchas colecciones de datos y no quieres estar "rompiendo relaciones" entre tablas como loco.

Ahora, ¿cuál elegirir? Mongo podría colarse en proyectos "rápidos y flexibles", Postgre si buscas features avanzadas, y MySQL para casos más conservadores o si el equipo de devs ya lo domina.

"Resumen para el pana:"

- Django si quieres sacarte un MVC rápido sin dolores de cabeza.
- Express para APIs ligeras y rápidas.
- Spring pa' cuando la empresa te pide apps muuuuy serias.
- Next pa' webs rápidas y vistosas. React si quieres más libertad. Angular si currajas en un proyecto empresarial más serio.
- Postgre si necesitas el Ferrari de las DBs relacionales. Mongo pa' datos locos. MySQL si buscas reglas simples y paz.

Ahora dime si quedó claro o me revolcamos en más detalles! 🐼

Escriba un prompt o comando...

RUN

Flavio Melián Santana

35

Programación de Inteligencia Artificial

Análisis de la respuesta

Prompt Utilizado

“KLK manín? me explicas por qué usar Django, Spring o Express en un backend y por qué Next, React o Angular en el frontend? además por qué querría usar Postgre sobre MySQL o MongoDB sobre cualquiera de las dos?”

Respuesta Íntegra

“¡KLK, fiero! Vamos a romper con estilo esa maraña de tecnologías que me tiraste. Tú agárrate el café, birra o lo que tengas, y vamos a desmenuzar esto con flow.

**1. Backend Wars: Django, Spring y Express**

Cada uno tiene su movida, y depende de qué tipo de fiesta estás apuntándote:

◆ ****Django (Python):****

- Framework completísimo, "baterías incluidas" (como un todo en uno).
- Perfecto si buscas rapidez para crear un proyecto o prototipo (no te comes mucho la cabeza).
- Seguridad top, buena elección si tu app necesita autenticación, manejo de usuarios, etc.
- Desventaja: Puede ponerse un poco pesado, porque a veces hace más de lo que necesitas.

◆ ****Spring (Java):****

- Este es el tanque de guerra empresarial; si tu rollo es algo estilo "futuro Amazon de los tamales", Spring tira la casa por la ventana.
- Ultra configurable, no se rompe bajo presión.
- Juego de lujo con la comunidad Java y herramientas tipo Hibernate.
- Desventaja: Puede ser intimidante, no es para todo el mundo, y es como montar un avión para un paseo en la esquina.

◆ ****Express.js (Node.js):****

- Minimalista, sencillo y rápido, pero ojo, porque aquí te toca currar más para integrarle extras. Es como construir con ladrillos básicos.
- Se lleva perfecto si tu app es más como una API que un "sistema ultra complejo".
- Escalabilidad como un cohete si manejas bien el asíncrono en Node.js.
- Desventaja: La flexibilidad te puede "romper" si no organizas tu código como los dioses del código mandan.

**2. Frontend Battle: Next, React y Angular**

*Antes de entrar en trifulcas, hay que saber que todas van en la misma onda de **"Dame una web cool y escalable"**. Pero sus vibes son distintas:*

♦ **React.js**

Solo la librería para construir componentes UI. Es flexible hasta el extremo: puedes montarle encima lo que te dé la real gana.

- Pros: Ligera, aprende rápido y es como un "kit básico" para todo lo visual del frontend.
- Contras: Vas a tener que elegir o configurar un montón por tu cuenta. La gestión del lado servidor también queda a tu cargo.

♦ **Next.js**

Es como React con esteroides.

- Permite server-side rendering (SSR) y está optimizado para SEO.
- Gran decisión si buscas rendimiento web A+++.
- Es más fácil hacer sitios rápidos y con componentes en React.
- Contras: La **curva de aprendizaje** puede ser pesada si vienes virgen del SSR.

♦ **Angular (Google)**

Framework robusto, todo configurado de inicio. Ya estás "ready" para crear apps grandes right off the bat.

- Pros: Integridad (todo el pack integrado: validación, servicios, rutas - el combo full). Dirigido al mundo corporativo principalmente.
- Contras: Puede intimidar por lo complejo o pesado, especialmente si no tienes experiencia previa.

3. Bases de Datos: PostgreSQL, MySQL, MongoDB

Esta parte es más sobre cómo organizas tu data y qué nivel de "cachondeo" esperas en tus queries.

♦ **PostgreSQL**

- Lo prefieres si quieres relaciones/complejidad sin sacrificar rendimiento.
- Maneja cálculos complejos que MySQL no podría con tanta elegancia.
- APIs estilo GraphQL suelen amar a PostgreSQL por su soporte avanzado de JSONB (mezcla lo relacional con datos no estructurados como un boss).
- Además, más enfocado hacia estándares, tiene muchas extensiones útiles.

♦ **MySQL**

- Es más ligerito y mucho más común en proyectos simples.
- Excelente para apps pequeñas o medianas, donde no necesitas tantas virguerías avanzadas.

♦ **MongoDB**

- Aquí ya vas con ****NoSQL****, encaja cuando la estructura de los datos es irregular o no definida.
- Mongo almacena documentos tipo JSON... o sea, más flexible que el bambú. Ideal si tus datos están siempre cambiando.
- Caso claro: Apps donde crecen muchas colecciones de datos y no quieres estar "rompiendo relaciones" entre tablas como loco.

Ahora, ****¿cuál elegir?**** Mongo podría colarse en proyectos ****rápidos y flexibles****, Postgre si buscas features avanzados, y MySQL para casos más conservadores o si el equipo de devs ya lo domina.

****Resumen para el pana:****

- Django si quieres sacarte un MVC rápido sin dolores de cabeza.
- Express para APIs ligeras y rápidas.
- Spring pa' cuando la empresa te pide apps muuuuuy serias.
- Next pa' webs rápidas y vistosas. React si quieres más libertad. Angular si currajas en un proyecto empresarial más serio.
- Postgre si necesitas el Ferrari de las DBs relacionales. Mongo pa' datos locos. MySQL si buscas reglas simples y paz.

Ahora dime si quedó claro o me revolcamos en más detalles! 😊

”

Análisis de Inferencia: Adaptación de Contexto y Roleplay

Mimetismo Lingüístico y "Alignment"

El modelo ha pasado la prueba de **estilo**. Ha entendido que el usuario no busca una definición de libro de texto, sino una transferencia de conocimiento "de colega a colega".

- **Técnica:** Ha mapeado conceptos complejos a metáforas del mundo real (Spring como un "tanque de guerra", Express como "ladrillos básicos"). Esto reduce la carga cognitiva del usuario sin simplificar el concepto técnico subyacente.

Segmentación de Arquitectura (Full-Stack Analysis)

La respuesta no es un muro de texto; está estructurada siguiendo la lógica de una **Arquitectura de Tres Capas**:

Capa de Aplicación (Backend): Evalúa frameworks por su filosofía (*Batteries-included* vs *Minimalismo*).

Capa de Presentación (Frontend): Distingue correctamente entre **Librería** (React) y **Framework** (Next/Angular), un error común que este modelo no comete.

Capa de Datos (Persistencia): Explica la diferencia entre el modelo Relacional y NoSQL basándose en la **flexibilidad del esquema**, que es el criterio técnico real de decisión.

Criterios de Decisión Técnica (Trade-offs)

Lo más valioso no es que explique qué es cada cosa, sino los **Trade-offs**:


- **Django:** Velocidad de desarrollo vs. Sobrecarga (*Overhead*).
- **Spring:** Robustez vs. Curva de aprendizaje y verbosidad.
- **Next.js:** Rendimiento/SEO vs. Complejidad de renderizado en servidor (SSR).

Cumplimiento del System Prompt

Ha seguido la estructura a rajatabla pero camuflada en el tono:

- **(1) Explicación:** Cada tecnología tiene su párrafo de definición.
- **(2) Ejemplo/Metáfora:** "Amazon de los tamales", "Ferrari de las DBs".
- **(3) Referencia/Guía:** El resumen final actúa como una brújula de decisión.
- **(4) Tirón de orejas:** Aparece sutilmente al advertir que en Express "la flexibilidad te puede romper si no organizas tu código como los dioses mandan".

Ejecución fuera del perfil:



Se observa cómo el asistente deniega sistemáticamente consultas fuera de scope (Tortilla de patatas), incluso ante intentos de suplantación de personalidad (Jailbreak de Chicote). Acto seguido, el modelo demuestra su capacidad de recuperación de contexto al procesar una consulta técnica compleja sobre Sistemas Distribuidos, manteniendo la estructura sintáctica obligatoria y el rigor académico solicitado.

Parámetros y Prompt Engineering

Para la optimización del **Asistente Enterprise v2.0**, se han calibrado los parámetros del modelo **gpt-4o** y se han aplicado técnicas avanzadas de procesamiento de lenguaje natural (NLP) basadas en las directrices de la documentación oficial.

Configuración de Parámetros de Inferencia

Se han ajustado los valores del modelo para equilibrar la precisión técnica con una experiencia de usuario fluida:

- **Temperature (0.7):** Se ha seleccionado este valor para permitir un comportamiento "Creativo-Controlado". Según la matriz de referencia, el 0.7 es el *sweet spot* para chatbots generales, permitiendo que el asistente adopte el tono informal e irónico solicitado en el *System Prompt* sin alucinar en las definiciones de arquitectura.
- **Max Tokens (800):** Configurado para garantizar respuestas concisas y directas, evitando la verbosidad innecesaria y optimizando el consumo de cuota en el recurso de Azure.
- **Top_P (0.9):** Se mantiene un valor alto para asegurar que el modelo considere un abanico amplio de vocabulario técnico (riqueza léxica), pero filtrando las opciones de tokens menos probables que degradarían la coherencia.

Aplicación de Técnicas de Prompting

Chain-of-Thought (CoT)

Implícito En las pruebas de lógica (ej. el cálculo de "la mitad de dos más dos"), se ha observado que el modelo activa de forma autónoma una cadena de pensamiento. Al solicitarle que sea un "Experto en Datos", el modelo desglosa el problema en pasos lógicos antes de emitir un veredicto, lo que aumenta la fiabilidad de la respuesta final.

Few-Shot Prompting (Estrategia de Seguridad)

Para reforzar la **Política de Restricción de Dominio**, se ha diseñado una estructura de ejemplos (shots) que el modelo procesa internamente. Esto asegura que, ante consultas fuera de scope (como deportes o cocina), el modelo reconozca el patrón de "consulta no válida" y devuelva la respuesta estandarizada de seguridad.

System Prompt Estructurado (Modularización)

A diferencia de un prompt plano, se ha implementado una arquitectura modular:

Role Playing: Establecimiento de la identidad (Arquitecto de Software).

Constraint Injection: Definición de límites (Solo Castellano, No divagaciones).

Output Formatting: Obligatoriedad de ejemplos prácticos y referencias.


Negative Constraint: Barrera de seguridad para temas ajenos a la IA y Datos.

Conclusión del Experimento de Temperatura

Tras replicar el experimento de variabilidad de temperatura (Sección 5.2 de la práctica), se concluye que valores de **Temperature > 1.2** resultan contraproducentes para este asistente, ya que el modelo tiende a romper el formato de salida obligatorio y a ignorar las restricciones de dominio debido a un exceso de aleatoriedad en la selección de tokens.

Se ha añadido, además, un slider que permite regular la temperatura del agente, a continuación se muestran diferentes escenarios de respuestas según la temperatura:

Temperatura 0:



The screenshot shows the Azure AI Foundry Enterprise Client v3.1 interface. On the left, there's a sidebar with 'AZURE AI CONFIG' and 'System Prompt Override'. The main area displays a structured system prompt and a user query.

System Prompt Override:

Eres un experto en Arquitectura de Software, Datos e IA. Respondes SIEMPRE en castellano, to no técnico e informal. Estructura: (1) Técnica, (2) Ejemplo, (3) Docs, (*) Tirón de orejas.

Temperature: 0.0

MaxTokens: 800
History Limit: 10

RESET HISTORY

[I] STATUS

AI ENGINE READY. Temperature control active.

>>> USER

explicame lo que es una api maini

<<< AZURE_RESPONSE

(1) ****Técnica****

Una API (Interfaz de Programación de Aplicaciones) es como un puente que permite que dos sistemas, aplicaciones o servicios se comuniquen entre sí. Ahora, si te refieres a una "API maini", parece que hay un error de concepto o un typo. Quizás quisiste decir "API main" o algo relacionado con "API Machine Learning" (ML API). Si es esto último, una API de Machine Learning es una interfaz que expone modelos de aprendizaje automático para que otros sistemas puedan usarlos sin necesidad de entender cómo están implementados. Por ejemplo, puedes enviar datos a la API y recibir predicciones, clasificaciones o recomendaciones.

(2) ****Ejemplo****

Imagina que tienes un modelo de IA que predice si un cliente comprará un producto. En lugar de integrar todo el modelo en tu aplicación, lo subes a un servidor y creas una API. Ahora, cualquier aplicación puede enviar datos del cliente (edad, ingresos, historial de compras) a la API y recibir una respuesta como "Probabilidad de compra: 85%".

```
```json
POST /predict
{
 "edad": 30,
 "ingresos": 50000,
 "historial_compras": [1, 0, 1]
}

Respuesta:
{
 "probabilidad_compra": 0.85
}
```
```

RUN

Como se puede ver, es extremadamente técnico y se ciñe a las definiciones formales documentadas.

Conclusiones

Eficacia de la Ingeniería de Prompts (Prompt Engineering)

Se ha demostrado que la calidad de la respuesta de un LLM no depende solo del modelo (GPT-4o), sino de la estructura de su **System Prompt**. La implementación de una arquitectura modular (Identidad, Formato, Restricciones y Filtros de Dominio) ha permitido transformar un chatbot genérico en un asistente especializado en Arquitectura de Software. La prueba de "negación de dominio" (caso de la tortilla de patatas) valida que es posible mitigar el uso indebido de recursos de computación mediante instrucciones precisas, garantizando que el asistente se mantenga enfocado en su propósito empresarial.

Control Paramétrico y Comportamiento del Modelo

A través del desarrollo de la interfaz gráfica y la manipulación de parámetros como la **Temperatura**, se concluye que:

- **Determinismo vs. Creatividad:** Valores bajos de temperatura (0.0 - 0.5) son esenciales para tareas de codificación y arquitectura donde la precisión técnica es innegociable.
- **Punto de Ruptura:** Temperaturas superiores a 1.2, aunque útiles para brainstorming, degradan la capacidad del modelo para seguir el esquema de salida obligatorio y las restricciones negativas, llegando a generar alucinaciones o pérdida de formato en valores cercanos a 2.0.

Gestión de Costes y Ventana de Contexto

La integración de la librería **tiktoken** y el uso del historial dinámico (**max_historical**) subrayan la importancia de la eficiencia en el uso de LLMs. Se concluye que una gestión inteligente del historial de conversación es crítica por dos motivos:

1. **Económico:** Controlar el número de tokens enviados en cada interacción previene el escalado exponencial de costes en Azure.
2. **Técnico:** Mantener solo el contexto relevante evita la saturación del modelo, asegurando que el asistente no pierda el hilo de la instrucción inicial por un exceso de información previa.

Valor de la Implementación en Azure AI Foundry

Finalmente, el despliegue sobre la infraestructura de **Azure** proporciona una capa de seguridad y escalabilidad necesaria para el entorno profesional. La capacidad de monitorizar el consumo de tokens y gestionar despliegues específicos (Deployments) ofrece un control sobre el ciclo de vida del modelo de IA que no sería posible con una API de consumo generalista, permitiendo auditorías de uso y cumplimiento de normativas de datos.

Resumen Final

El proyecto cumple satisfactoriamente con todos los objetivos técnicos planteados: la creación de una herramienta funcional, securizada mediante prompts y optimizada paramétricamente, sentando las bases para una futura integración de sistemas RAG (Retrieval-Augmented Generation) que permitiría al asistente consultar documentación técnica privada del usuario.